

Beyond RAG

Architectures à états agentiques pour des statistiques économiques fiables

Minh Ha-Duong

CIREN – CNRS

Econom'IA 2026 — Thema, Cergy — 27 mai 2026

CIREN – CNRS

Problème

Les modèles de transition énergétique ont besoin de données par centrale.

Modèles d'expansion, simulations de réseau, inventaires d'émissions — tous nécessitent des tableaux de centrales électriques avec combustible, statut, capacité, localisation.

Dans les pays à offices statistiques faibles, ces données sont compilées manuellement par des experts. Lent, coûteux, pas scalable.

L'IA peut-elle produire des données de qualité recherche ?

Pourquoi c'est difficile :

- **Multilingue** — diacritiques vietnamiens, translittérations multiples
- **Dispersé** — PDPs, rapports EVN, décrets gouvernementaux

Vietnam thermique (163 centrales) est la tâche pilote.

Enjeu régional : des centaines de GW de capacité planifiée dispersée dans des dizaines de plans nationaux en ASEAN.

La question centrale

57 modèles. Un plafond. Le même pour tous.

La question n'est pas « quel modèle ? »

C'est « quelle architecture ? »

Les données de qualité recherche ne sont pas des données correctes.

Ce sont des données dont les erreurs sont **localisables**.

*Cet exposé : ce qui accroche, ce qui permet la localisabilité,
et où mènent les architectures à états agentiques.*

Quatre défaillances, quatre solutions architecturales

Défaillance	Sans correction	Réponse architecturale
Ancrage ¹	Chiffres sans sources	RAG massif
Auditabilité ²	Affirmations non traçables	Citations par cellule
Fraîcheur	Instantané figé à la coupure	Fusion incrémentale
Fiabilité ³	Cellules incertaines non signalées	Vérif. 3 niveaux

Chaque section présente une défaillance et son mécanisme correcteur.

¹van Fraassen, *The Scientific Image*, 1980.

²Popper, *The Logic of Scientific Discovery*, 1959.

³Intersubjectivité : accord entre auditeurs indépendants.

57 modèles × 5 méthodes × 3 répétitions

\$0,82 au total — Vietnam, 163 centrales thermiques

Facteur	Valeurs testées	Enjeu
Documentation	aucune, multi-tours, RAG massif	Ancrage
Décomposition	pas unique, par combustible	Couverture
Agrégation	meilleur run, vote union	Rappel
Modèle	57 de 10 laboratoires	Contrôle

Le modèle est un facteur parmi d'autres.

Pourquoi ne pas simplement vérifier la sortie ?

Trois options :

Confiance Accepter le tableau. (Pas de vérification de provenance.)

Vérifier Contrôler chaque ligne sur les sources. Corriger.

Conserver. (Rapide : ~3h pour 162 lignes.)

Re-extraire Corpus validé, extraction indépendante, LLM pour la couverture uniquement.
(Plus lent, mais réutilisable.)

La vérification suffit pour un tableau.

Plafond :

- Ne peut trouver les **86 centrales manquantes**
- Pas de mise à jour si PDP8 est révisé
- Ne se transfère pas au pays suivant
- Tableau vérifié, pas un processus réutilisable

Vérification LLM post-hoc : 0–10%
d'accord.

(Barème 0–4 : les modèles rappellent des citations depuis leur connaissance paramétrique. Des opinions, pas de la provenance.)

De l'extraction à la fusion d'information

RAG traite l'extraction comme *document* → *tableau* en une passe.

Le vrai problème est la **fusion** : fragments divers accumulés dans un tableau via un processus contrôlé, inspectable.

Trois types de fragments :

- **Sériels** (tableaux : annexes PDP, EVN)
— alignement de schéma + liaison d'enregistrements
- **Multi-scalaires** (listes prose) —
vérification d'existence ;
confirme/ajoute des lignes
- **Scalaires** (faits isolés) — mise à jour d'attribut : remplit les cellules

La primitive de fusion :

master + fragment → master'

Une source à la fois. Jamais tous les fragments en une passe.

Conséquences :

- Chaque étape a un diff inspectable
- Coût en N , pas en $N \times S$
- Auditable par construction
- L'échec est localisé à une étape

C'est le **à états** dans « à états agentiques. »


Ancrage documentaire

Régime de documentation : le RAG élève le plancher

Mêmes 5 modèles testés dans 3 conditions méthodologiques × 3 runs Coût total : \$0.89

Niveaux de documentation :

1. **Aucun** – passe unique, connaissance paramétrique uniquement
2. **Multi-tours** – 3 relances conversationnelles
3. **RAG massif** – 18 tableaux sources sélectionnés (155 ko) comme contexte système



Corpus RAG : tableaux vérifiés

Documentation : inversion coût-performance

Corpus : 18 tableaux Markdown vérifiés manuellement (155 ko) depuis des sources officielles

Modèle	Direct	+ RAG
Mistral Small 4 (\$0.15/M)	83	141
GPT-5.4 (\$2.50/M)	107	126
Gemini Flash Lite (\$0.10/M)	91	126
Mistral Large 3 (\$0.50/M)	62	118
DeepSeek V3.2 (\$0.26/M)	63	98

Médiane des centrales trouvées (sur 163), 3 runs chacun

Documents du corpus :

- Annexes PDP7, PDP7A, PDP8
- Rapports annuels EVN 2010–2018
- Tableaux de l'étude E542
- Rapports 32 et 58

Résultat clé :

Avec des documents, un modèle bon marché surpasse un modèle coûteux.

La **méthode** (RAG) domine le choix^{10/23}

Quels modules du prompt comptent ?


[Résultats d'ablation en attente — ticket 0038]

Module	$\Delta F1$ param.	$\Delta F1$ RAG	Impact
Persona	—	—	—
Vue d'ensemble secteur	—	—	—
Narratifs	—	—	—
Bibliographie	—	—	—
Tableau croisé	—	—	—
Sourçage par ligne	—	—	—

Ablation sur 6 modules, régimes paramétrique et RAG.

C'est le résultat central qui justifie « Beyond RAG » comme titre.

Pareto coût-qualité : les méthodes, pas les modèles



Meilleur point Pareto : DeepSeek V3.2 décomposé+RAG — F1 moyen=89,8% [85,8–95,6%] à \$0.06.

Auditabilité

Responsabilité épistémique : LLM vs pipeline

Propriété	Rapport LLM	Pipeline de fusion
Provenance	« Claude l'a dit »	cellule → ID source → document
Mise à jour	régénérer tout	ajouter une source
Audit	opaque	journal d'étapes + sidecar + registre
Falsifiable	non	vérifier la source contre l'affirmation
Incrémental	non	actif par actif, source par source
À états	non	registre + mémoire persistants

Le LLM est un **index compressé**.

Utiliser pour la *découverte de périmètre*, pas comme vérité terrain.

Extraction sourcée (3 runs Opus) :

≈100% des centrales citent une source corpus.

≈98% des citations tracent vers un fichier.

≈80% traçables de bout en bout.

Auditabilité : les chiffres

≈**100%** des centrales citent une source corpus

≈**98%** des citations tracent vers un fichier corpus

≈**80%** traçables de bout en bout

(citation → fichier → nom de centrale)

Extraction sourcée, 3 runs Opus,
température = 0

RAG décomposé (meilleur F1=89,8%) :
0% traçable — aucune citation émise.

Couverture vs. traçabilité : le compromis ouvert.

Fraîcheur

Fusion incrémentale : mise à jour sans régénération

Primitive : $\text{master} + \text{doc}_i \longrightarrow \text{master}'$, 18 itérations (ordre chronologique).

Ce que cela apporte :

- Chaque document ajouté de façon incrémentale — pas de re-exécution complète
- Chaque mise à jour est un diff : localisable, réversible
- Le coût croît en N sources, pas en $N \times S$

Mode	F1 à $N=18$
Incrémental	88,0 %
Global	46,2 %

Précision : 100 % (aucun faux positif)

Couverture incrémentale : 78,5 %

F1 incrémental croît monotonement ; F1 global

s'effondre à $N=18$ (instabilité de contexte).

Fiabilité

Vérification à l'échelle : trois niveaux

Niveau	Mécanisme
Pré-filtre	Audit des diffs : seules les cellules modifiées sont vérifiées
1	Correspondance exacte (déterministe) cellule $\leftrightarrow$ table source
2	Arbitrage LLM sur les échecs du niveau 1 $\rightarrow$ règle candidate
3	Ratification HITL $\rightarrow$ règle en mémoire (piste d'audit)

Ce que cela apporte :

- Déterminisme en premier ; LLM uniquement en recours
- L'humain ne ratifie qu'*une fois* par règle
- La mémoire rend le run $N + 1$ moins coûteux que le run N
- Le taux d'escalade est lui-même un

Métriques :

- Taux d'escalade par étape de fusion
- Croissance du nombre de règles (par taxonomie)
- Taux d'acceptation des ratifications

Impasse évitée : jurys multi-agents (ticket 0059). Ici l'humain valide chaque règle une

Mémoire HITL et agents v0

Quatre catégories de règles :

- **Alias** — identité d'entité
« VT1 » $\equiv$ « Vinh Tan 1 »
- **Unité/format** — normalisation
« 1 200 MW » $\rightarrow$ 1200
- **Terme source-local** — vocabulaire
prose
« Nhóm » (PDP8) = « Group »
- **Synonyme d'attribut** — colonne
 $\rightarrow$ schéma
« Công suất » $\rightarrow$ capacity_mw

Quatre agents :

Watcher découverte de sources

Curator triage HITL

Analyst fusion chronologique
 $\rightarrow$ mute master + sidecar

Auditor vérification 3 niveaux
 $\rightarrow$ propose + ratifie des règles

L'état est persistant. Registre, sidecar, journal, mémoire : tous sous git.

Le run suivant reprend là où celui-ci s'est arrêté. C'est le chemin vers 60 campagnes.

Architecture

La réponse architecturale : 4 couches × 4 agents

Quatre couches de données :

1. **Dépôt de documents** — sources brutes en cache
2. **Corpus validé** — indexé, registre des sources
3. **Master + sidecar** — fusion incrémentale,
master.csv + provenance + fusion_log
4. **Mémoire** — règles auditées par taxonomie
aliases / unités / termes-sources + audit.jsonl

Quatre agents, chacun ancré sur un critère :

Watcher découverte → *Fraîcheur*

Curator triage HITL → *Ancrage*

Analyst fusion chronologique → *Fraîcheur*

Auditor vérification 3 niveaux → *Fiabilité*

L'état est persistant. Registre, sidecar, journal, mémoire : tous sous git.

C'est un travail en cours vers cette vision

Qualité du résultat : échelle d'ancrage par donnée

Score		Statut épistémique
5		Corroboré : deux sources primaires <i>indépendantes</i> confirmées
4		Confirmé : une source primaire validée (HITL ou recouplement factuel)
3		Falsifiable : une source primaire identifiée par heuristique domaine
2		Faiblement falsifiable : une source secondaire (peut être dérivée)
1		Non falsifiable : aucune source proposée
0		Fabriqué : source vérifiée et trouvée fausse

Ce pilote opère aux niveaux 3–4. Atteindre le niveau 5 exige une carte de dépendance des producteurs de données sectoriels.

Qualité de la méthode : les conditions actives

Niveau		Garantie apportée (cumulative)
4	■	Fiabilité : vérification 3 niveaux (auto → HITL → recouplement)
3	■	Fraîcheur : fusion incrémentale, état persistant versionnable sous git
2	■	Auditabilité : citation par cellule, traçabilité source-à-chiffre
1	■	Ancrage : sources documentaires injectées (RAG massif)
0	■	Paramétrique : connaissance mémorisée seule, aucune source externe

Ce pilote mesure les transitions $0 \rightarrow 1$ (RAG) et $1 \rightarrow 2$ (décomposition + agrégation). Les niveaux 3–4 font l'objet du benchmark de phases 2+3.

Perspectives

Trois leçons

1. **La méthode domine le modèle.**

Documentation (+18–43 pp), décomposition (60% → 99%) et agrégation (+35 pp) surpassent le choix du modèle. 57 modèles, un plafond commun.

2. **Chaque critère de qualité s'améliore par une intervention architecturale mesurable.**

Ancrage → RAG. Auditabilité → citations par cellule. Fraîcheur → fusion incrémentale. Fiabilité → vérification 3 niveaux.

3. **Le pipeline est auditable ; le LLM seul, non.**

80% traçables bout-en-bout (extraction sourcée) vs. 0% (RAG décomposé). Les erreurs sont *localisables*.

Pourquoi un graphe de connaissances ?

v0 est relationnel. Master + sidecar + registre sont des CSV. Cela suffit pour un pays, un secteur, une chaîne de sources.

Un **graphe de connaissances** devient nécessaire à trois frontières :

Résolution d'entités à l'échelle « Vinh Tan 1 », « VT1 », « Vĩnh Tân 1 », « Vinh Tan Unit 1 » sont une seule centrale. v0 gère cela avec un dépôt de règles d'alias. Un KG le gère nativement comme arêtes d'identité — entre pays et langues.

Provenance multi-sauts Un chiffre de capacité sourcé depuis PDP7, révisé par PDP8, confirmé par EVN est un *chemin* dans un graphe. Forcer cela dans un sidecar plat perd la structure nécessaire à l'audit et au raisonnement défaisable.

Fusion inter-domaines Les centrales sont liées aux entreprises, permis, opérateurs de réseau, bilans d'émissions. ASEAN × 6 types de combustibles × données

Merci !

Code & données : `github.com/minhhaduong/aedist-technical-report`