

Beyond RAG

Architectures à états agentiques pour des statistiques économiques fiables

Minh Ha-Duong

CIREN – CNRS

Econom'IA 2026 — Thema, Cergy — 27 mai 2026

CIREN – CNRS

Problème

Le fossé

Les modèles de transition énergétique ont besoin de données par centrale.

Modèles d'expansion, simulations de réseau, inventaires d'émissions — tous nécessitent des tableaux de centrales électriques avec combustible, statut, capacité, localisation.

Dans les pays à offices statistiques faibles, ces données sont compilées manuellement par des experts. Lent, coûteux, pas scalable.

L'IA peut-elle produire des données de qualité recherche ?

Nous pilotons cette question sur une tâche — centrales thermiques vietnamiennes — pour

Pourquoi c'est difficile :

- **Multilingue** — diacritiques vietnamiens, translittérations multiples
- **Temporel** — plans annuels, centrales déclassées ou annulées
- **Technique** — MW_e vs MW_{th} , centrale vs unité vs turbine
- **Dispersé** — PDPs, rapports EVN, décrets gouvernementaux

Vietnam thermique (163 centrales) est la tâche pilote.

L'approche évidente : interroger l'IA

Un prompt : 77 centrales, \$0.02, 30 secondes.

Avec RAG + décomposition : 163/163, F1=89,8%, \$0.06.

Aller plus loin : raisonnement + sous-agents

→ 77k car., 162 lignes, 46 réf., \$0.79, 8 min.


14 modèles, 10 laboratoires : gamme impressionnante, schéma d'incertitude cohérent.

Les deux approches partagent le même plafond :

- Quelles centrales manquent et pourquoi ?
- Les capacités sont-elles exactes ?
- 46 réf. — aucune vérifiée par machine
- Pas de mise à jour incrémentale
- Fonctionnerait-ce pour l'Indonésie ?
- Parieriez-vous une politique dessus ?

Un tableau plausible en quelques

57 modèles, 163 centrales : le modèle seul ne suffit pas



Passe unique, sans documentation. Ligne verte : référence (163 centrales). **Le choix du modèle ne résout pas le problème.**

La question centrale

Un tableau plausible en quelques secondes.

Mais peut-on lui faire confiance — sans reddition cognitive ?

Les données de qualité recherche ne sont pas des données correctes.

Ce sont des données dont les erreurs sont **localisables**.

*Cet exposé : ce qui accroche, ce qui permet la localisabilité,
et où mènent les architectures à états agentiques.*

Qu'est-ce qui rend des statistiques de qualité recherche ?

« Les données de qualité recherche ne sont pas des données correctes.
Ce sont des données dont les erreurs sont **localisables**. »

Critère	Échec sans lui	Mécanisme
Ancrage ¹	Chiffres sans sources	RAG massif
Auditabilité ²	Affirmations non traçables	Citations par cellule
Fraîcheur	Instantané figé à la coupure	Fusion incrémentale
Fiabilité ³	Cellules incertaines non signalées	Vérif. 3 niveaux

Chaque diapositive de résultats montre un critère amélioré par un choix architectural.

¹van Fraassen, *The Scientific Image*, 1980.

²Popper, *The Logic of Scientific Discovery*, 1959.

³Intersubjectivité : accord entre auditeurs indépendants comme critère de validité.

AEDIST v1 : l'architecture cible

Quatre couches de données :

1. **Dépôt de documents** — sources brutes en cache
2. **Corpus validé** — indexé, registre des sources
3. **Master + sidecar** — fusion incrémentale,
master.csv + provenance + fusion_log
4. **Mémoire** — règles auditées par taxonomie
aliases / unités / termes-sources + audit.jsonl

Quatre agents, chacun ancré sur un critère :

Watcher découverte → *Fraîcheur*

Curator triage HITL → *Ancrage*

Analyst fusion chronologique → *Fraîcheur*

Auditor vérification 3 niveaux → *Fiabilité*

L'état est persistant. Registre, sidecar, journal, mémoire : tous trackés sous git.

C'est un travail en cours vers cette vision

Pourquoi ne pas simplement vérifier la sortie ?

Trois options :

Confiance Accepter le tableau. (Pas de vérification de provenance.)

Vérifier Contrôler chaque ligne sur les sources. Corriger.

Conserver. (Rapide : ~3h pour 162 lignes.)

Re-extraire Corpus validé, extraction indépendante, LLM pour la couverture uniquement. (Plus lent, mais réutilisable.)

La vérification suffit pour un tableau.

Plafond :

- Ne peut trouver les **86 centrales manquantes**
- Pas de mise à jour si PDP8 est révisé
- Ne se transfère pas au pays suivant
- Tableau vérifié, pas un processus réutilisable

Vérification LLM post-hoc : 0–10%
d'accord.

(Barème 0–4 : les modèles rappellent des citations depuis leur connaissance paramétrique. Des opinions, pas de la provenance.)

De l'extraction à la fusion d'information

RAG traite l'extraction comme *document* → *tableau* en une passe.

Le vrai problème est la **fusion** : fragments divers accumulés dans un tableau via un processus contrôlé, inspectable.

Trois types de fragments :

- **Sériels** (tableaux : annexes PDP, EVN)
— alignement de schéma + liaison d'enregistrements
- **Multi-scalaires** (listes prose) —
vérification d'existence ;
confirme/ajoute des lignes
- **Scalaires** (faits isolés) — mise à jour d'attribut : remplit les cellules

La primitive de fusion :

master + fragment → master'

Une source à la fois. Jamais tous les fragments en une passe.

Conséquences :

- Chaque étape a un diff inspectable
- Coût en N , pas en $N \times S$
- Auditable par construction
- L'échec est localisé à une étape

C'est le **à états** dans « à états agentiques. »

Ancrage documentaire

Conception du pilote

Tâche : lister toutes les centrales thermiques vietnamiennes avec combustible, statut, province, capacité (CSV).

Référence : 163 centrales, validées par des experts depuis PDP7, PDP8, rapports EVN.

Conception :

Hypothèse Une **méthode** = modèle + prompt + régime d'information + agrégation. Le modèle est un facteur parmi d'autres.

Échelle 57 modèles, \$0.82 au total

Conditions clés Documentation × Conversation × Décomposition × Agrégation ×
Modèle (57)

Métrique clé : centrales trouvées sur 163.


La couverture varie de 4 à 163 ; la précision varie de 27% à 100%.

Régime de documentation : le RAG élève le plancher

Mêmes 5 modèles testés dans 3 conditions méthodologiques × 3 runs Coût total : \$0.89

Niveaux de documentation :

1. **Aucun** – passe unique, connaissance paramétrique uniquement
2. **Multi-tours** – 3 relances conversationnelles
3. **RAG massif** – 18 tableaux sources sélectionnés (155 ko) comme contexte système



Centrales identifiées (un point = une centrale)

Corpus RAG : tableaux vérifiés

Documentation : inversion coût-performance

Corpus : 18 tableaux Markdown vérifiés manuellement (155 ko) depuis des sources officielles

Modèle	Direct	+ RAG
Mistral Small 4 (\$0.15/M)	83	141
GPT-5.4 (\$2.50/M)	107	126
Gemini Flash Lite (\$0.10/M)	91	126
Mistral Large 3 (\$0.50/M)	62	118
DeepSeek V3.2 (\$0.26/M)	63	98

Médiane des centrales trouvées (sur 163), 3 runs chacun

Documents du corpus :


- Annexes PDP7, PDP7A, PDP8
- Rapports annuels EVN 2010–2018
- Tableaux de l'étude E542
- Rapports 32 et 58

Résultat clé :

Avec des documents, un modèle bon marché surpasse un modèle coûteux.

La **méthode** (RAG) domine le choix^{12/25}

Pareto coût-qualité : les méthodes, pas les modèles



Meilleur point Pareto : DeepSeek V3.2 décomposé+RAG — F1 moyen=89,8% [85,8–95,6%] à \$0.06.

Auditabilité

Responsabilité épistémique : LLM vs pipeline

Propriété	Rapport LLM	Pipeline de fusion
Provenance	« Claude l'a dit »	cellule → ID source → document
Mise à jour	régénérer tout	ajouter une source
Audit	opaque	journal d'étapes + sidecar + registre
Falsifiable	non	vérifier la source contre l'affirmation
Incrémental	non	actif par actif, source par source
À états	non	registre + mémoire persistants

Le LLM est un **index compressé**.

Utiliser pour la *découverte de périmètre*, pas comme vérité terrain.

Extraction sourcée (3 runs Opus) :

≈100% des centrales citent une source corpus (médiane 100%, min 99%).

≈98% des citations tracent vers un fichier corpus (médiane 98%).

≈**80% traçables de bout en bout**

Fraîcheur

Fusion incrémentale : mise à jour sans régénération

Primitive : $\text{master} + \text{doc}_i \longrightarrow \text{master}'$, 18 itérations (ordre chronologique).

Ce que cela apporte :

- Chaque document ajouté de façon incrémentale — pas de re-exécution complète
- Chaque mise à jour est un diff : localisable, réversible
- Le coût croît en N sources, pas en $N \times S$

Mode	F1 à $N=18$
Incrémental	88,0 %
Global	46,2 %

Précision : 100 % (aucun faux positif)

Couverture incrémentale : 78,5 %

F1 incrémental croît monotonement ; F1 global

s'effondre à $N=18$ (instabilité de contexte).

Fiabilité

Vérification à l'échelle : trois niveaux

Niveau	Mécanisme
Pré-filtre	Audit des diffs : seules les cellules modifiées sont vérifiées
1	Correspondance exacte (déterministe) cellule $\leftrightarrow$ table source
2	Arbitrage LLM sur les échecs du niveau 1 $\rightarrow$ règle candidate
3	Ratification HITL $\rightarrow$ règle en mémoire (piste d'audit)

Ce que cela apporte :

- Déterminisme en premier ; LLM uniquement en recours
- L'humain ne ratifie qu'*une fois* par règle
- La mémoire rend le run $N + 1$ moins coûteux que le run N
- Le taux d'escalade est lui-même un

Métriques :

- Taux d'escalade par étape de fusion
- Croissance du nombre de règles (par taxonomie)
- Taux d'acceptation des ratifications

Impasse évitée : jurys multi-agents (ticket 0059). Ici l'humain valide chaque règle une

Mémoire HITL auditée : quatre catégories de règles

Catégorie	Encode	Exemple	Déclenché
Alias	identité d'entité	« VT1 » $\equiv$ « Vinh Tan 1 »	après échec correspon
Unité/format	forme de valeur	« 1 200 MW » $\rightarrow$ 1200	avant correspondant
Terme source-local	vocab. prose	« Nhóm » (PDP8) = « Group »	dans l'arbitrage LL
Synonyme d'attribut	colonne $\rightarrow$ schéma	« Công suất » $\rightarrow$ capacity_mw	au chargement du t

Chaque règle porte une piste d'audit :

- Suggestion LLM qui l'a proposée
- Humain ratificateur
- Horodatage
- Cellule d'évidence

Mémoire HITL auditée

**Les règles sont des annotations,
pas des substitutions mécaniques.**

Chaque règle porte un raisonnement,
des cas limites et des preuves —
un carnet de terrain pour le
prochain statisticien, pas un
sed LLM glorifié.

AEDIST v0 : agents ancrés sur les préoccupations du modèle de données

Quatre couches d'information :

1. **Dépôt de documents** — fichiers bruts en cache
2. **Corpus validé** — indexé Zotero ; *registre des sources* réside ici
3. **Master + sidecar** — sortie de fusion
master.csv + master_provenance.csv + fusion_log.csv
4. **Mémoire** — dépôt de règles par taxonomie
aliases / units / source-terms / attribute-synonyms + audit.jsonl

Agents, chacun responsable d'une préoccupation :

- Watcher découverte de sources
- Curator triage de sources HITL
→ écrit les entrées du registre
- Analyst exécute la primitive de fusion
(ordre chronologique avec arbitrage d'autorité)
→ mute master + sidecar
→ ajoute à fusion_log
- Auditor exécute la vérification 3

Qualité du résultat : échelle d'ancrage par donnée

Score		Statut épistémique (Popper + OTAN STANAG 2022)
5		Corroboré : deux sources primaires <i>indépendantes</i> confirmées
4		Confirmé : une source primaire validée (HITL ou recouplement factuel)
3		Falsifiable : une source primaire identifiée par heuristique domaine
2		Faiblement falsifiable : une source secondaire (peut être dérivée)
1		Non falsifiable : aucune source proposée
0		Fabriqué : source vérifiée et trouvée fausse

Ce pilote opère aux niveaux 3–4. Atteindre le niveau 5 exige une carte de dépendance des producteurs de données sectoriels.

Qualité de la méthode : les conditions actives

Niveau		Garantie apportée (cumulative)
4	■	Fiabilité : vérification 3 niveaux (auto → HITL → recouplement)
3	■	Fraîcheur : fusion incrémentale, état persistant trackable sous git
2	■	Auditabilité : citation par cellule, traçabilité source-à-chiffre
1	■	Ancrage : sources documentaires injectées (RAG massif)
0	■	Paramétrique : connaissance mémorisée seule, aucune source externe

Ce pilote benchmark les transitions $0 \rightarrow 1$ (RAG) et $1 \rightarrow 2$ (décomposition + agrégation). Les niveaux 3–4 font l'objet du benchmark de phases 2+3.

Qualité du modèle : le modèle comme instrument de mesure

Niveau		Propriété garantie
4		Corroboré : accord entre modèles indépendants (intersubjectivité)
3		Calibré : prompt validé par ablation sur la tâche cible
2		Reproductible : seed + provider fixés ; repeat ≥ 3 pour les MoE
1		Déterministe : température = 0
0		Non contrôlé : modèle choisi sans protocole de mesure

Ce pilote atteint le niveau 2 (température + seed). L'ablation (Phase 0) vise le niveau 3. La corroboration inter-modèles (niveau 4) est mesurée par l'accord min-de-5.

Perspectives

Ce que nous avons appris sur les méthodes

Conditions méthodologiques, classées par impact :

1. **Documentation** (RAG) : +18 à +43 pp
2. **Décomposition** : 60% → 99%
3. **Agrégation** (vote union) : +35 pp à coût nul
4. **Conversation** (multi-tours) : gain marginal vs. passe unique
5. Choix du modèle seul : 0–161 centrales

Leçon :

La méthode utilisée importe plus que le

Chiffres clés :

- 57 modèles, 6 axes de conditions, \$0.82
- Meilleure ligne de base : 125/163 (modèle seul)
- Meilleur RAG : 141/163 (modèle bon marché + docs)
- **Meilleur global : 163/163, F1 moyen=89,8% [85,8–95,6%], \$0.06**

Conclusion :

Un pipeline standard avec les bonnes **conditions méthodologiques** retrouve

Ce que ce pilote a mesuré — et ce qu'il n'a pas mesuré

Ce que le pilote établit :

- Les conditions méthodologiques (RAG, décomposition, agrégation) important plus que le choix du modèle
- Un pipeline standard retrouve 89,8% [85,8–95,6%] d'un inventaire expert pour \$0.06
- Faisabilité de l'évaluation automatisée via la réconciliation floue

Ce qu'il ne peut pas distinguer :

- **Extraction vs. rappel** — les modèles entraînés sur PDP7/PDP8 peuvent réciter, pas extraire
- **Spécifique vs. général** — une référence (N=163), un pays, un secteur
- **Signal vs. bruit** — 3 runs, F1 ponctuel, pas d'intervalles de confiance
- **Interactions de méthodes** — axes testés séparément, jamais composés
- **Température** — 211/280 runs ont

Pourquoi un graphe de connaissances ?

v0 est relationnel. Master + sidecar + registre sont des CSV. Cela suffit pour un pays, un secteur, une chaîne de sources.

Un **graphe de connaissances** devient nécessaire à trois frontières :

Résolution d'entités à l'échelle « Vinh Tan 1 », « VT1 », « Vĩnh Tân 1 », « Vinh Tan Unit 1 » sont une seule centrale. v0 gère cela avec un dépôt de règles d'alias. Un KG le gère nativement comme arêtes d'identité — entre pays et langues.

Provenance multi-sauts Un chiffre de capacité sourcé depuis PDP7, révisé par PDP8, confirmé par EVN est un *chemin* dans un graphe. Forcer cela dans un sidecar plat perd la structure nécessaire à l'audit et au raisonnement défaisable.

Fusion inter-domaines Les centrales sont liées aux entreprises, permis, opérateurs de réseau, bilans d'émissions. ASEAN $\times$ 6 types de combustibles $\times$ données

Merci !

Code & données : `github.com/minhhaduong/aedist-technical-report`