

# Beyond RAG

Architectures à états agentiques pour des statistiques économiques fiables

---

Minh Ha-Duong

CIREN – CNRS

Econom'IA 2026 — Thema, Cergy — 27 mai 2026

CIREN – CNRS

# Problème

---

# Le fossé

## Les modèles de transition énergétique ont besoin de données par centrale.

Modèles d'expansion, simulations de réseau, inventaires d'émissions — tous nécessitent des tableaux de centrales électriques avec combustible, statut, capacité, localisation.

Dans les pays à offices statistiques faibles, ces données sont compilées manuellement par des experts. Lent, coûteux, pas scalable.

## L'IA peut-elle produire des données de qualité recherche ?

Nous pilotons cette question sur une tâche — centrales thermiques vietnamiennes — pour

## Pourquoi c'est difficile :

- **Multilingue** — diacritiques vietnamiens, translittérations multiples
- **Temporel** — plans annuels, centrales déclassées ou annulées
- **Technique** —  $MW_e$  vs  $MW_{th}$ , centrale vs unité vs turbine
- **Dispersé** — PDPs, rapports EVN, décrets gouvernementaux

Vietnam thermique (163 centrales) est la tâche pilote.

# L'approche évidente : interroger l'IA

**Un prompt** : 77 centrales, \$0.02, 30 secondes.

Avec RAG + décomposition : 163/163, F1=89,8%, \$0.06.

**Aller plus loin** : raisonnement + sous-agents

→ 77k car., 162 lignes, 46 réf., \$0.79, 8 min.


14 modèles, 10 laboratoires : gamme impressionnante, schéma d'incertitude cohérent.

**Les deux approches partagent le même plafond :**

- Quelles centrales manquent et pourquoi ?
- Les capacités sont-elles exactes ?
- 46 réf. — aucune vérifiée par machine
- Pas de mise à jour incrémentale
- Fonctionnerait-ce pour l'Indonésie ?
- Parieriez-vous une politique dessus ?

Un tableau plausible en quelques

# 37 modèles, 163 centrales : le modèle seul ne suffit pas



Passe unique, sans documentation. Ligne verte : référence (163 centrales). **Le choix du modèle ne résout pas le problème.**

# La question centrale

Un tableau plausible en quelques secondes.

**Mais peut-on lui faire confiance — sans reddition cognitive ?**

Les données de qualité recherche ne sont pas des données correctes.

Ce sont des données dont les erreurs sont **localisables**.

*Cet exposé : ce qui accroche, ce qui permet la localisabilité,  
et où mènent les architectures à états agentiques.*

# Qu'est-ce qui rend des statistiques de qualité recherche ?

« Les données de qualité recherche ne sont pas des données correctes.  
Ce sont des données dont les erreurs sont **localisables**. »

| Critère                          | Échec sans lui                     | Mécanisme             |
|----------------------------------|------------------------------------|-----------------------|
| <b>Ancrage</b> <sup>1</sup>      | Chiffres sans sources              | RAG massif            |
| <b>Auditabilité</b> <sup>2</sup> | Affirmations non traçables         | Citations par cellule |
| <b>Fraîcheur</b>                 | Instantané figé à la coupure       | Fusion incrémentale   |
| <b>Fiabilité</b> <sup>3</sup>    | Cellules incertaines non signalées | Vérif. 3 niveaux      |

Chaque diapositive de résultats montre un critère amélioré par un choix architectural.

<sup>1</sup>van Fraassen, *The Scientific Image*, 1980.

<sup>2</sup>Popper, *The Logic of Scientific Discovery*, 1959.

<sup>3</sup>Intersubjectivité : accord entre auditeurs indépendants comme critère de validité.

# AEDIST v1 : l'architecture cible

## Quatre couches de données :

1. **Dépôt de documents** — sources brutes en cache
2. **Corpus validé** — indexé, registre des sources
3. **Master + sidecar** — fusion incrémentale,  
master.csv + provenance + fusion\_log
4. **Mémoire** — règles auditées par taxonomie  
aliases / unités / termes-sources + audit.jsonl

## Quatre agents, chacun ancré sur un critère :

**Watcher** découverte → *Fraîcheur*

**Curator** triage HITL → *Ancrage*

**Analyst** fusion chronologique → *Fraîcheur*

**Auditor** vérification 3 niveaux → *Fiabilité*

**L'état est persistant.** Registre, sidecar, journal, mémoire : tous trackés sous git.

C'est un travail en cours vers cette vision



# Pourquoi ne pas simplement vérifier la sortie ?

## Trois options :

Confiance Accepter le tableau. (Pas de vérification de provenance.)

Vérifier Contrôler chaque ligne sur les sources. Corriger.

Conserver. (Rapide : ~3h pour 162 lignes.)

Re-extraire Corpus validé, extraction indépendante, LLM pour la couverture uniquement. (Plus lent, mais réutilisable.)

## La vérification suffit pour un tableau.

Plafond :

- Ne peut trouver les **86 centrales manquantes**
- Pas de mise à jour si PDP8 est révisé
- Ne se transfère pas au pays suivant
- Tableau vérifié, pas un processus réutilisable

**Vérification LLM post-hoc : 0–10%**  
d'accord.

(Barème 0–4 : les modèles rappellent des citations depuis leur connaissance paramétrique. Des opinions, pas de la provenance.)

# De l'extraction à la fusion d'information

RAG traite l'extraction comme *document* → *tableau* en une passe.

Le vrai problème est la **fusion** : fragments divers accumulés dans un tableau via un processus contrôlé, inspectable.

## Trois types de fragments :

- **Sériels** (tableaux : annexes PDP, EVN)  
— alignement de schéma + liaison d'enregistrements
- **Multi-scalaires** (listes prose) —  
vérification d'existence ;  
confirme/ajoute des lignes
- **Scalaires** (faits isolés) — mise à jour d'attribut : remplit les cellules

## La primitive de fusion :

master + fragment → master'

Une source à la fois. Jamais tous les fragments en une passe.

## Conséquences :

- Chaque étape a un diff inspectable
- Coût en  $N$ , pas en  $N \times S$
- Auditable par construction
- L'échec est localisé à une étape

C'est le **à états** dans « à états agentiques. »

## Ancrage documentaire

---

# Conception du pilote

**Tâche** : lister toutes les centrales thermiques vietnamiennes avec combustible, statut, province, capacité (CSV).

**Référence** : 163 centrales, validées par des experts depuis PDP7, PDP8, rapports EVN.

## Conception :

Hypothèse Une **méthode** = modèle + prompt + régime d'information + agrégation. Le modèle est un facteur parmi d'autres.

Échelle 37 modèles, \$0.82 au total

Conditions clés Documentation × Conversation × Décomposition × Agrégation ×  
Modèle (37)

**Métrique clé** : centrales trouvées sur 163


(précision >99% sur tous les modèles — le problème est la **couverture**, pas l'hallucination)

# Régime de documentation : le RAG élève le plancher

Mêmes 5 modèles testés dans 3 conditions méthodologiques × 3 runs    Coût total : \$0.89

## Niveaux de documentation :

1. **Aucun** – passe unique, connaissance paramétrique uniquement
2. **Multi-tours** – 3 relances conversationnelles
3. **RAG massif** – 18 tableaux sources sélectionnés (155 ko) comme contexte système



Corpus RAG : tableaux vérifiés

# Documentation : inversion coût-performance

**Corpus** : 18 tableaux Markdown vérifiés manuellement (155 ko) depuis des sources officielles

| Modèle                       | Direct | + RAG      |
|------------------------------|--------|------------|
| Mistral Small 4 (\$0.15/M)   | 83     | <b>141</b> |
| GPT-5.4 (\$2.50/M)           | 107    | <b>126</b> |
| Gemini Flash Lite (\$0.10/M) | 91     | <b>126</b> |
| Mistral Large 3 (\$0.50/M)   | 62     | <b>118</b> |
| DeepSeek V3.2 (\$0.26/M)     | 63     | <b>98</b>  |

Médiane des centrales trouvées (sur 163), 3 runs chacun

## Documents du corpus :


- Annexes PDP7, PDP7A, PDP8
- Rapports annuels EVN 2010–2018
- Tableaux de l'étude E542
- Rapports 32 et 58

## Résultat clé :

Avec des documents, un modèle bon marché surpasse un modèle coûteux.

La **méthode** (RAG) domine le choix<sup>12/25</sup>

# Pareto coût-qualité : les méthodes, pas les modèles



Meilleur point Pareto : DeepSeek V3.2 décomposé+RAG — F1 moyen=89,8% [85,8–95,6%] à \$0.06.

# Auditabilité

---



# Responsabilité épistémique : LLM vs pipeline

| Propriété   | Rapport LLM        | Pipeline de fusion                      |
|-------------|--------------------|-----------------------------------------|
| Provenance  | « Claude l'a dit » | cellule → ID source → document          |
| Mise à jour | régénérer tout     | ajouter une source                      |
| Audit       | opaque             | journal d'étapes + sidecar + registre   |
| Falsifiable | non                | vérifier la source contre l'affirmation |
| Incrémental | non                | actif par actif, source par source      |
| À états     | non                | registre + mémoire persistants          |

Le LLM est un **index compressé**.

Utiliser pour la *découverte de périmètre*, pas comme vérité terrain.

**Extraction sourcée (3 runs Opus) :**

≈100% des centrales citent une source corpus (médiane 100%, min 99%).

≈98% des citations tracent vers un fichier corpus (médiane 98%).

**≈80% traçables de bout en bout**

Fraîcheur

---

# Fusion incrémentale : mise à jour sans régénération

**Primitive** :  $\text{master} + \text{doc}_i \longrightarrow \text{master}'$ , 18 itérations (ordre chronologique).

## Ce que cela apporte :

- Chaque document ajouté de façon incrémentale — pas de re-exécution complète
- Chaque mise à jour est un diff : localisable, réversible
- Le coût croît en  $N$  sources, pas en  $N \times S$

| Mode        | F1 à $N=18$   |
|-------------|---------------|
| Incrémental | <b>88,0 %</b> |
| Global      | 46,2 %        |

Précision : 100 % (aucun faux positif)

Couverture incrémentale : 78,5 %

F1 incrémental croît monotonement ; F1 global

s'effondre à  $N=18$  (instabilité de contexte).

Fiabilité

---

# Vérification à l'échelle : trois niveaux

| Niveau     | Mécanisme                                                                   |
|------------|-----------------------------------------------------------------------------|
| Pré-filtre | Audit des diffs : seules les cellules modifiées sont vérifiées              |
| 1          | Correspondance exacte (déterministe) cellule $\leftrightarrow$ table source |
| 2          | Arbitrage LLM sur les échecs du niveau 1 $\rightarrow$ règle candidate      |
| 3          | Ratification HITL $\rightarrow$ règle en mémoire (piste d'audit)            |

## Ce que cela apporte :

- Déterminisme en premier ; LLM uniquement en recours
- L'humain ne ratifie qu'*une fois* par règle
- La mémoire rend le run  $N + 1$  moins coûteux que le run  $N$
- Le taux d'escalade est lui-même un

## Métriques :

- Taux d'escalade par étape de fusion
- Croissance du nombre de règles (par taxonomie)
- Taux d'acceptation des ratifications

Impasse évitée : jurys multi-agents (ticket 0059). Ici l'humain valide chaque règle une

# Mémoire HITL auditée : quatre catégories de règles

| Catégorie           | Encode                       | Exemple                                 | Déclenché             |
|---------------------|------------------------------|-----------------------------------------|-----------------------|
| Alias               | identité d'entité            | « VT1 » $\equiv$ « Vinh Tan 1 »         | après échec correspon |
| Unité/format        | forme de valeur              | « 1 200 MW » $\rightarrow$ 1200         | avant correspondant   |
| Terme source-local  | vocab. prose                 | « Nhóm » (PDP8) = « Group »             | dans l'arbitrage LLM  |
| Synonyme d'attribut | colonne $\rightarrow$ schéma | « Công suất » $\rightarrow$ capacity_mw | au chargement du t    |

**Chaque règle porte une piste d'audit :**

- Suggestion LLM qui l'a proposée
- Humain ratificateur
- Horodatage
- Cellule d'évidence

Mémoire HITL auditée

**Les règles sont des annotations,  
pas des substitutions mécaniques.**

Chaque règle porte un raisonnement,  
des cas limites et des preuves —  
un carnet de terrain pour le  
prochain statisticien, pas un  
sed LLM glorifié.

# AEDIST v0 : agents ancrés sur les préoccupations du modèle de données

## Quatre couches d'information :

1. **Dépôt de documents** — fichiers bruts en cache
2. **Corpus validé** — indexé Zotero ; *registre des sources* réside ici
3. **Master + sidecar** — sortie de fusion  
master.csv + master\_provenance.csv + fusion\_log.csv
4. **Mémoire** — dépôt de règles par taxonomie  
aliases / units / source-terms / attribute-synonyms + audit.jsonl

## Agents, chacun responsable d'une préoccupation :

- Watcher découverte de sources
- Curator triage de sources HITL  
→ écrit les entrées du registre
- Analyst exécute la primitive de fusion  
(ordre chronologique avec arbitrage d'autorité)  
→ mute master + sidecar  
→ ajoute à fusion\_log
- Auditor exécute la vérification 3

## Qualité du résultat : échelle d'ancrage par donnée

| Score |                                                                                   | Statut épistémique (Popper + OTAN STANAG 2022)                               |
|-------|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| 5     |  | <b>Corroboré</b> : deux sources primaires <i>indépendantes</i> confirmées    |
| 4     |  | <b>Confirmé</b> : une source primaire validée (HITL ou recouplement factuel) |
| 3     |  | <b>Falsifiable</b> : une source primaire identifiée par heuristique domaine  |
| 2     |  | <b>Faiblement falsifiable</b> : une source secondaire (peut être dérivée)    |
| 1     |  | <b>Non falsifiable</b> : aucune source proposée                              |
| 0     |  | <b>Fabriqué</b> : source vérifiée et trouvée fausse                          |

Ce pilote opère aux niveaux 3–4. Atteindre le niveau 5 exige une carte de dépendance des producteurs de données sectoriels.



# Qualité de la méthode : les conditions actives

| Niveau |   | Garantie apportée (cumulative)                                             |
|--------|---|----------------------------------------------------------------------------|
| 4      | ■ | <b>Fiabilité</b> : vérification 3 niveaux (auto → HITL → recouplement)     |
| 3      | ■ | <b>Fraîcheur</b> : fusion incrémentale, état persistant trackable sous git |
| 2      | ■ | <b>Auditabilité</b> : citation par cellule, traçabilité source-à-chiffre   |
| 1      | ■ | <b>Ancrage</b> : sources documentaires injectées (RAG massif)              |
| 0      | ■ | <b>Paramétrique</b> : connaissance mémorisée seule, aucune source externe  |

Ce pilote benchmark les transitions  $0 \rightarrow 1$  (RAG) et  $1 \rightarrow 2$  (décomposition + agrégation). Les niveaux 3–4 font l’objet du benchmark de phases 2+3.

# Qualité du modèle : le modèle comme instrument de mesure

| Niveau |                                                                                   | Propriété garantie                                                          |
|--------|-----------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| 4      |  | <b>Corroboré</b> : accord entre modèles indépendants (intersubjectivité)    |
| 3      |  | <b>Calibré</b> : prompt validé par ablation sur la tâche cible              |
| 2      |  | <b>Reproductible</b> : seed + provider fixés ; repeat $\geq 3$ pour les MoE |
| 1      |  | <b>Déterministe</b> : température = 0                                       |
| 0      |  | <b>Non contrôlé</b> : modèle choisi sans protocole de mesure                |

Ce pilote atteint le niveau 2 (température + seed). L'ablation (Phase 0) vise le niveau 3. La corroboration inter-modèles (niveau 4) est mesurée par l'accord min-de-5.

## Perspectives

---

# Ce que nous avons appris sur les méthodes

## Conditions méthodologiques, classées par impact :

1. **Documentation** (RAG) : +18 à +43 pp
2. **Décomposition** : 60% → 99%
3. **Agrégation** (vote union) : +35 pp à coût nul
4. **Conversation** (multi-tours) : gain marginal vs. passe unique
5. Choix du modèle seul : 0–161 centrales

## Leçon :

La méthode utilisée importe plus que le

## Chiffres clés :

- 57 modèles, 6 axes de conditions, \$0.82
- Meilleure ligne de base : 125/163 (modèle seul)
- Meilleur RAG : 141/163 (modèle bon marché + docs)
- **Meilleur global : 163/163, F1 moyen=89,8% [85,8–95,6%], \$0.06**

## Conclusion :

Un pipeline standard avec les bonnes **conditions méthodologiques** retrouve

# Ce que ce pilote a mesuré — et ce qu'il n'a pas mesuré

## Ce que le pilote établit :

- Les conditions méthodologiques (RAG, décomposition, agrégation) important plus que le choix du modèle
- Un pipeline standard retrouve 89,8% [85,8–95,6%] d'un inventaire expert pour \$0.06
- Faisabilité de l'évaluation automatisée via la réconciliation floue

## Ce qu'il ne peut pas distinguer :

- **Extraction vs. rappel** — les modèles entraînés sur PDP7/PDP8 peuvent réciter, pas extraire
- **Spécifique vs. général** — une référence (N=163), un pays, un secteur
- **Signal vs. bruit** — 3 runs, F1 ponctuel, pas d'intervalles de confiance
- **Interactions de méthodes** — axes testés séparément, jamais composés
- **Température** — 211/280 runs ont

# Pourquoi un graphe de connaissances ?

**v0 est relationnel.** Master + sidecar + registre sont des CSV. Cela suffit pour un pays, un secteur, une chaîne de sources.

Un **graphe de connaissances** devient nécessaire à trois frontières :

Résolution d'entités à l'échelle « Vinh Tan 1 », « VT1 », « Vĩnh Tân 1 », « Vinh Tan Unit 1 » sont une seule centrale. v0 gère cela avec un dépôt de règles d'alias. Un KG le gère nativement comme arêtes d'identité — entre pays et langues.

Provenance multi-sauts Un chiffre de capacité sourcé depuis PDP7, révisé par PDP8, confirmé par EVN est un *chemin* dans un graphe. Forcer cela dans un sidecar plat perd la structure nécessaire à l'audit et au raisonnement défaisable.

Fusion inter-domaines Les centrales sont liées aux entreprises, permis, opérateurs de réseau, bilans d'émissions. ASEAN  $\times$  6 types de combustibles  $\times$  données

**Merci !**

Code & données : `github.com/minhhaduong/aedist-technical-report`